10주차

AI는 데이터에서 무엇을 보는가



AI는 무엇을 보고 판단하고, 왜 엉뚱하게 틀릴까?

학습 목표

01 AI가 데이터 속 '특징(단서)'을 보고 판단한다는 것을 설명할 수 있다

02 AI가 학습데이터에 따라 엉뚱한 것을 배울 수 있음을 사례로 설명할 수 있다

03 조건을 바꿔 가며 AI가 틀리는 이유를 추론할 수 있다

PART 01

AI는 데이터를 어떻게 볼까



사진도 글도, AI에게는 숫자

AI의 눈에는 숫자만 보인다

0	0	0	0	0	0	0	0
0	255	255	255	255	255	255	0
0	120	0	0	0	120	255	0
0	0	0	0	0	255	0	0
0	0	0	0	255	120	0	0
0	0	0	120	255	0	0	0
0	0	0	255	0	0	0	0
0	0	0	0	0	0	0	0

사진 = 숫자 표

작은 점(픽셀)마다 밝기를 0~255 숫자로 기록한다. 사람은 '7'을 보지만 AI는 숫자 64개를 받는다

실제 사진은 훨씬 크다

스마트폰 사진 한 장 = 숫자 수백만 개

숫자만으로는 부족하다

고양이가 조금만 움직여도 숫자는 확 바뀐다. 고양이라는 사실은 그대로인데

그래서 AI는 숫자 속에서 '의미 있는 단서'를 찾아야 한다 → 이것이 특징(feature)

좋은 단서의 세 가지 조건

특징 = 대상을 구별하는 데 도움이 되는 단서



잘 구별해 준다

고양이와 개에서 확실히 다르게 나타난다

예: 귀 모양



쉽게 변하지 않는다

옆에서 찍든, 어두운 데서 찍든 그대로다

예: 얼굴 생김새



대상 자체에서 나온다

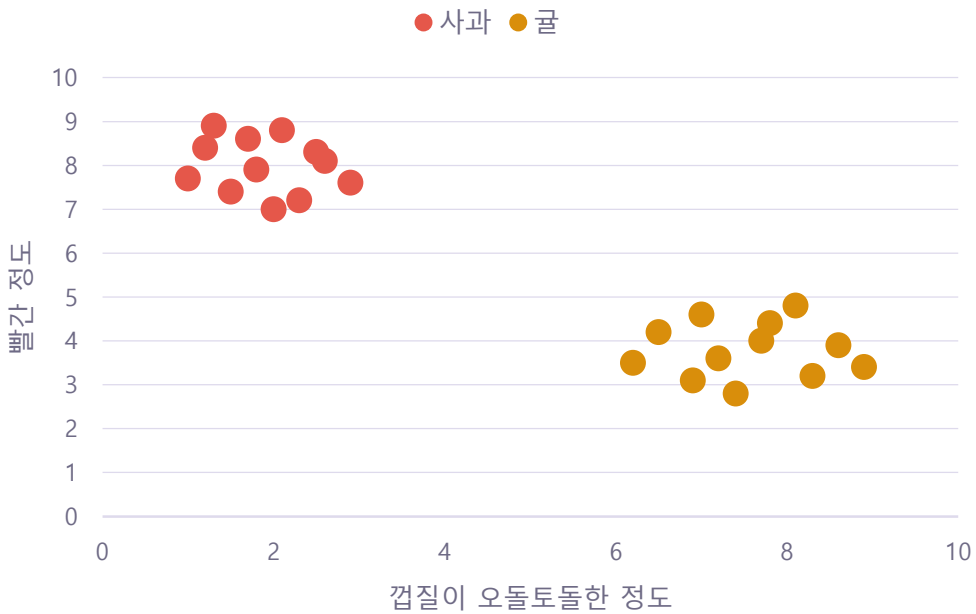
우연히 같이 찍힌 것이 아니다

나쁜 예: 사진 속 배경

구별은 잘 되는데 대상과 상관없는 단서가 가장 위험하다 — 한스에게 질문자의 표정처럼

단서로 그리는 지도

단서 두 개를 고르면, 데이터를 지도 위의 점으로 찍을 수 있다



(수업용 가상 데이터)

AI가 하는 일 = 선 긋기

사과 무리와 귤 무리 사이에 경계선을 긋는다. 지난주 트리도 이렇게 선을 그었다.

단서를 잘 고르면 쉽다

두 무리가 멀리 떨어져 있으면 선 하나로 끝난다.

주의

상관없는 단서라도 두 무리를 잘 나눠 주면, AI는 그것을 쓴다.

데이터 종류마다 단서가 다르다

사진

선, 색, 무늬 → 눈·귀 같은 부분 → 전체 모양

예: 사진 속 물체 알아보기

글

어떤 단어가 몇 번, 어떤 순서로 나오는지

예: 스팸 메일 걸러내기

숫자 표

키, 기온, 점수 같은 값과 그 조합

예: 키·몸무게 → BMI

여러분 전공의 데이터라면, 판단의 핵심 단서는 무엇일까?

글에서 찾는 단서: 스팸 메일

단어	정상 메일 100통	스팸 메일 100통
무료	3번	58번
당첨	1번	41번
회의	37번	2번
!!!	5번	66번

(표의 숫자는 수업용 예시)

단어 세기

'무료', '당첨'이 많이 나오면 스팸일 가능성이 높다

흔한 단어는 빼기

'오늘', '안녕하세요'처럼 어디에나 나오는 단어는 단서가 안 된다

비슷한 뜻 묶기

'무료'와 '공짜'를 같은 뜻으로 알아보게 하는 방법도 있다 → 다음 주와 연결

생각해 보기: '무료'를 '무.료'로 쓰면? AI가 쓰는 단서를 알면 AI를 속일 수도 있다

단서는 누가 정할까?

사람이 정해 준다

- 전문가가 '귀 모양을 봐라'처럼 단서를 지정
- 장점: AI가 무엇을 보는지 안다
- 단점: 사람이 못 떠올린 단서는 놓친다

AI가 스스로 찾는다 (딥러닝)

- 사진과 정답만 주면 단서를 알아서 찾는다
- 장점: 사람보다 많은 단서를 찾는다
- 단점: 무엇을 골랐는지 알기 어렵다

AI가 받은 지시는 '정답을 맞혀라'뿐 — '올바른 이유로 맞혀라'는 지시는 없었다

AI는 단서를 레고처럼 쌓는다

딥러닝 이미지 AI가 사진을 보는 순서

01

선과 경계

가로선, 세로선, 밝기가 바뀌는 곳

02

무늬와 모양

털 무늬, 동그라미, 곡선

03

부분

눈, 귀, 코, 바퀴

04

판단

'고양이일 확률 92%'

92%는 '고양이를 이해했다'가 아니라
'학습할 때 본 고양이 사진들과 닮았다'는 뜻

퀴즈: 가장 위험한 단서는?

피부 사진으로 피부암(흑색종)인지 판단하는 AI를 만든다면

A

테두리가 울퉁불퉁한 정도

B

병변 안의 색이 여러 가지인지

C

병변의 크기

D

피부에 펜으로 그린 표시

정답 D

A·B·C는 병변 자체의 특징. 펜 표시는 의사가 '의심스럽다'고 표시해 둔 흔적일 뿐이다. 학습 사진 속 암 사진에 펜 표시가 많으면, AI는 '펜 표시 = 암'이라고 배워 버린다.

실제 연구: 펜 표시가 있으면 암이 아닌데도 암으로 판단하는 경우가 크게 늘었다 (Winkler 외, 2019)

PART 02

AI는 무엇을 배울까



학습데이터가 곧 AI의 경험

AI는 이렇게 배운다

01

모으기

사진을 많이 모은다

02

정답 달기

사진마다 '고양이', '개' 이름표

03

연습하기

맞히고 틀리며 단서를 고친다

04

시험 보기

따로 둔 사진으로 점수 확인

05

실전

처음 보는 사진을 판단

AI의 목표는 오직 '정답 맞히기' → 쉽게 맞힐 수 있는 단서라면 무엇이든 쓴다
시험 사진도 같은 방식으로 모았다면 → 엉뚱한 단서로도 점수는 높게 나온다

지름길 학습: 족보만 외운 학생

연구자들이 붙인 이름: shortcut learning (Geirhos 외, 2020)

“연습 문제와 비슷하면 잘 맞히지만, 문제가 조금만 바뀌면 틀리는 공부”

01

우연한 단서가 있다

정답과 우연히 함께 나오는 것 (예: 늑대 사진엔 늘 눈밭)

02

그게 더 쉽다

동물 모양보다 배경 색이 훨씬 알아보기 쉽다

03

상황이 바뀌면 틀린다

그 단서가 없는 곳에서 판단이 무너진다

한스가 산수 대신 질문자의 표정을 배운 것과 같다

사례 1 · 늑대일까, 허스키일까?

(2016)의 실험 — 일부러 치우친 사진으로 학습시킴

학습에 쓴 사진

- 늑대: 모두 눈밭
- 허스키: 눈이 없는 배경

→ '배경이 하얀가'가 가장 쉬운 단서

AI가 실제로 본 것

- 동물이 아니라 배경의 눈
- 눈밭에 있는 허스키 → '늑대'
- AI가 본 곳을 보여 주자 사람들의 신뢰가 뚝 떨어졌다

정답을 맞혔다고 해서 올바른 이유로 맞힌 것은 아니다

사례 2 · 병원 X선, AI는 무엇을 봤나

실제 의료 데이터에서 일어난 일

무슨 일이 있었나

- 여러 병원의 X선으로 폐렴을 찾는 AI 학습
- 병원마다 폐렴 환자 비율이 달랐다
- AI는 X선만 보고 어느 병원인지 알아맞혔다

왜 문제일까

- 병원 표시, 기계 흔적이 '폐렴 단서'가 됐다
- 학습한 병원에서는 성적이 좋았다
- 다른 병원에서는 성적이 떨어졌다

질문: 이런 문제를 미리 잡으려면 어떻게 시험을 봐야 할까?

사례 3 · 모양을 볼까, 무늬를 볼까?

(2019)의 실험



실험 사진
모양은 고양이
무늬는 코끼리 가죽

→

사람의 답

고양이

모양을 보고 판단

AI의 답

코끼리

무늬를 보고 판단

무늬는 사진 일부만 봐도 알 수 있는 '쉬운 단서'
무늬를 섞은 사진으로 다시 학습시키자 AI도 모양을 더 보게 됐다

학습데이터가 AI를 망치는 세 가지 방식

양이 치우칠 때

특정 집단의 사진이 적으면 그 집단을 더 자주 틀린다

정답이 틀릴 때

사람이 잘못 단 이름표를 그대로 정답으로 배운다

우연한 단서가 섞일 때

배경, 병원 표시, 펜 자국처럼 정답과 상관없는 것을 배운다

쓰레기를 넣으면 쓰레기가 나온다 — 그런데 그 쓰레기는 대개 멀쩡해 보인다

숫자로 보는 문제의 크기

양이 치우치면 · 얼굴 인식 AI

0.8%

피부가 밝은 남성
틀린 비율

34.7%

피부가 어두운 여성
틀린 비율(최대)

Gender Shades 연구 (Buolamwini & Gebru, 2018)

정답이 틀리면 · AI 시험용 데이터

3.3%

유명 데이터 10개의
평균 이름표 오류

6%

ImageNet 시험 데이터
이름표 오류(추정)

Northcutt 외 (2021)

평균 점수 하나로는 AI가 누구에게, 왜 틀리는지 알 수 없다

내가 AI 개발자라면

피부암 찾기 앱의 학습 사진을 모으는 규칙 3가지를 정해 보자



01 **양 치우침**을 막는 규칙

02 **틀린 정답**을 막는 규칙

03 **우연한 단서**를 막는 규칙

5분 토의 → 2~3개 발표

쉬는 시간 10분



실습 준비: 노트북·태블릿, Teachable Machine 접속과 웹캠 확인

PART 03

조건이 바뀌면 AI는 왜 틀릴까?



연습과 실전이 다를 때

연습 문제와 실전 문제가 다르면

AI는 학습 때 본 사진과 비슷한 사진에서만 믿을 만하다

학습 때 본 사진

- 밝은 낮
- 정면에서 찍은 사진
- 깔끔하고 익숙한 배경

실제로 만나는 사진

- 밤, 역광
- 위·옆·뒤에서 찍은 사진
- 복잡하고 낯선 배경, 일부 가림

실전이 달라지면 학습 사진에서만 통하던 우연한 단서가 사라진다
→ 숨어 있던 지름길이 드러나는 순간 (이를 '분포 변화'라고 부른다)

AI를 흔드는 네 가지 조건

각도

위나 옆에서 찍으면 모양이 달라 보인다

조명

어둡거나 역광이면 색과 윤곽이 잘 안 보인다

배경

낯선 배경이 판단을 엉뚱한 쪽으로 끌고 간다

가림

중요한 부분이 가려지면 남은 부분에 의지한다

사람에게는 쉬운 변화도, 학습 때 못 본 조건이면 AI에게는 처음 보는 문제
→ 그래서 학습 사진을 일부러 돌리고, 어둡게 만들어 섞어 주기도 한다

실제로 있었던 AI의 실수

상황	AI의 판단	왜 틀렸을까
해변에 서 있는 소	소를 알아보지 못함	학습한 소 사진이 대부분 풀밭 → 배경까지 외움
스티커 몇 장 붙인 정지 표지판	다른 표지판으로 인식	작은 변화에도 AI의 단서가 크게 흔들림
바나나 옆 특이한 무늬 스티커	'토스터'로 인식	강한 무늬가 바나나를 덮어 버림
어두운 곳에서 찍은 얼굴	못 알아보거나 다른 사람으로 판단	어둠 때문에 단서가 사라짐

공통점: AI는 대상만이 아니라 학습할 때의 '조건'까지 함께 외운다

눈에 안 보이는 노이즈로 AI 속이기

(2015)의 실험 — 판다 사진에 계산된 노이즈를 더하자 AI의 답이 바뀌었다

원래 사진

판다

57.7%

AI의 답: 판다

57.7%

\+

사람 눈에는 보이지 않음

노이즈 (×0.007)

사람 눈에는 보이지 않음

=

AI의 답

긴팔원숭이

99.3%

노이즈를 더한 사진

AI의 답: 긴팔원숭이

99.3%

AI가 보는 단서는 사람과 다를 수 있고, '99% 확신'이라도 틀릴 수 있다

출처: Goodfellow, I. J., Shlens, J., & Szegedy, C. (2015). Explaining and harnessing adversarial examples. ICLR. Figure 1 · arxiv.org/abs/1412.6572

AI가 어디를 봤는지 확인하는 방법

가려 보기

일부를 가렸을 때 확률이 크게 떨어지면, 그곳이 AI가 본 곳
→ 오늘 실습에서 직접!

조각 켜고 끄기

사진을 조각으로 나눠 어떤 조각이 판단을 도왔는지 찾기 (LIME)

열지도로 보기

AI가 중요하게 본 곳을 빨갛게 칠해서 보여 주기 (Grad-CAM)

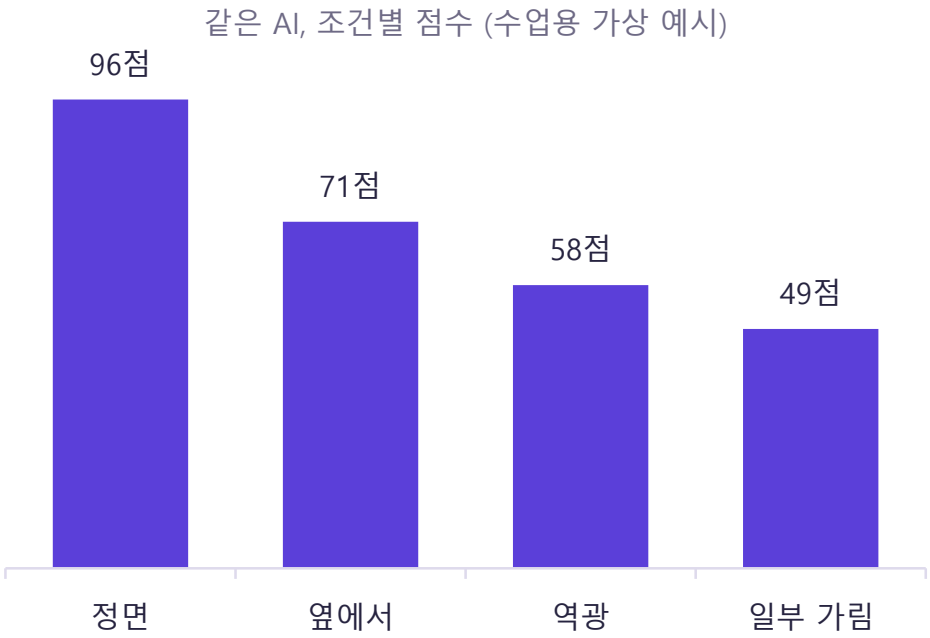
이 방법들도 완벽하진 않다 — 정답이 아니라 '단서'로 활용하기

AI가 틀렸을 때 던질 세 가지 질문

무엇을 봤을까?	물건 자체가 아니라 배경·색·소품을 본 건 아닐까?
본 적이 있을까?	학습할 때 이런 각도·조명·배경의 사진이 있었을까?
무엇이 사라졌을까?	가려지거나 어두워져서 중요한 단서가 안 보이게 된 건 아닐까?

이유에는 꼭 근거를 — 가장 좋은 근거는 '조건을 바꿨더니 확률이 이만큼 변했다'

평균 점수의 함정



조건별로 나눠 보기

정면, 옆, 역광... 따로 점수를 매긴다

다른 곳 데이터로 시험

학습에 안 쓴 병원·장소의 데이터로 확인한다

가장 낮은 점수부터

평균보다 가장 약한 경우를 먼저 본다

PART 04

실습: AI 헷갈리게 만들기



직접 학습시키고, 조건을 바꾸고, 이유를 찾는다

실습 개요 · 두 개의 실험

도구: Teachable Machine (웹캠으로 바로 학습 + 확률이 실시간으로 보임)

실험 A · 조건 바꾸기 (약 14분)

- 물건 2~3개를 기준 사진으로 학습
- 각도·조명·배경·가림을 하나씩 바꾸기
- AI의 답과 확률 기록하기

실험 B · 지름길 만들기 (약 14분)

- 물건마다 배경 색을 정해 놓고 학습
- 배경을 서로 바꿔서 테스트
- AI가 물건을 배웠는지, 배경을 배웠는지 확인

이후 10분: 정리와 발표 · 사람 얼굴, 학생증 등 개인정보는 찍지 않기

실험 A · 조건 바꾸기

01

학습시키기

밝은 곳·정면·깔끔한 배경에서 물건마다 50장 이상 촬영

02

기준 확인

같은 조건에서 AI의 답과 확률 기록

03

하나씩 바꾸기

각도 → 조명 → 배경 → 가림. 조건마다 3번 확인

04

이유 찾기

세 가지 질문 + 어디를 가렸을 때 확률이 가장 떨어지나?

가장 중요한 규칙: 한 번에 하나만 바꾼다 — 두 개를 같이 바꾸면 이유를 알 수 없다

실험 B · 지름길 만들기

01

단서 심기

물건 A는 파란 종이, 물건 B는 흰 종이 위에서만 촬영

02

확인하기

같은 조건에서 잘 맞히는지 확인

03

배경 바꾸기

A를 흰 종이, B를 파란 종이에 놓고 테스트

04

종이만 보여 주기

물건 없이 종이만 보여 주면 AI는 뭐라고 할까?

먼저 예상해 보기 **AI가 물건을 배웠다면? 배경을 배웠다면?**

시간이 남으면: 두 배경을 섞어 다시 학습시키고 결과 비교하기

기록 예시 · 머그컵 (실험 A)

조건	바꾼 것	AI의 답 (확률)	맞음?	이유와 근거
기준	정면, 흰 책상	컵 (95%)	○	손잡이와 원통 모양
각도	위에서 내려다봄	그릇 (61%)	×	손잡이가 안 보여 동그란 모양만 남음
가림 ①	손잡이를 가림	컵 (48%)	△	확률이 절반 가까이 떨어짐 → 손잡이가 중요
가림 ②	몸통 아래를 가림	컵 (91%)	○	거의 그대로 → ①과 비교하면 확실해짐

맞았는지보다 확률이 얼마나 변했는지가 더 중요한 증거 · 실습 28분

예상

어떤 조건에서 틀릴 거라 생각했나

결과

가장 많이 틀린 조건과 확률 변화

이유와 근거

세 가지 질문으로 찾은 이유

개선 방법

학습 사진을 어떻게 바꾸면 나아질까

실험 B도 함께: 배경을 바꿨을 때 AI는 뭐라고 답했나?

핵심 정리

01 **AI는 숫자 속 '특징(단서)'을 보고 판단한다**

좋은 단서 = 잘 구별하고, 쉽게 안 변하고, 대상 자체에서 나온 것

02 **AI는 학습데이터에서 가장 쉬운 단서를 배운다**

우연한 단서가 섞이면 지름길 학습 → 정답을 맞혀도 이유는 엉뚱할 수 있다

03 **조건이 바뀌면 숨은 지름길이 드러난다**

높은 점수·높은 확률만 믿지 말고, 조건을 바꿔 가며 확인하기