11주차

AI는 데이터에서 무엇을 보는가

질문하는 트리에서, 눈이 생긴 AI로

SW중심대학사업단 연구교수 염희균(yeom@dju.kr)

오늘의 흐름

1교시
AI는 사진을 어떻게 '읽을까'?

- 트리의 **변수** → AI의 **특징**
- 좋은 단서 vs 함정 단서
- 스팸 메일, 사과·토마토 예시
- **함께 해보기①** 단서 찾기 게임

2교시
AI는 무엇을 보고 맞혔을까?

- 영리한 말 '한스' 이야기
- 늑대와 허스키: 눈을 본 AI
- 학습데이터가 만드는 편향
- 퀴즈: 이 AI는 무엇을 봤을까?

3교시
조건이 바뀌면 왜 틀릴까?

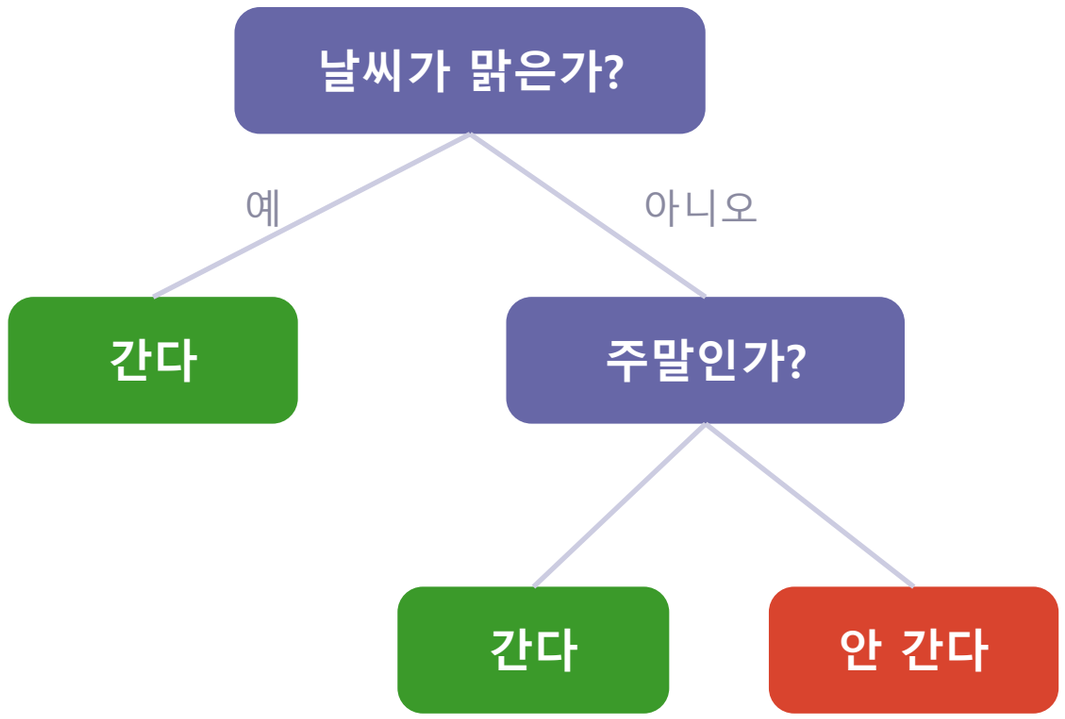
- 각도·조명·배경·가림
- 사람 눈엔 같은데 AI는 다르다
- **함께 해보기②** 같은 물건, 다른 조건
- 틀린 이유 추론하기

한 문장으로 이어 보면: AI가 보는 '**단서(특징)**'를 알아보고 → 그 단서가 **학습데이터**에서 온다는 것을 확인하고 → 조건을 바꿔 AI가 **속는 이유**를 추론한다

지난주 마지막 장면에서 이어서: 트리는 '열'을 골랐다

트리의 질문 = 표의 열(변수). 그 열은 사람이 정리해서 건네준 것이었다

지난주 트리: 놀이공원에 갈까?



질문 하나하나가 표의 '열' 하나

지난주 데이터: 열마다 이름이 있다

날씨	주말	기온	놀이공원
맑음	예	높음	간다
흐림	예	높음	간다
비	아니오	낮음	안 간다
맑음	아니오	낮음	간다

→ 트리는 **날씨·주말·기온** 중에서 '가장 잘 가르는 열'을 **골랐다**

→ 열 이름은 처음부터 있었다 (예시 표)

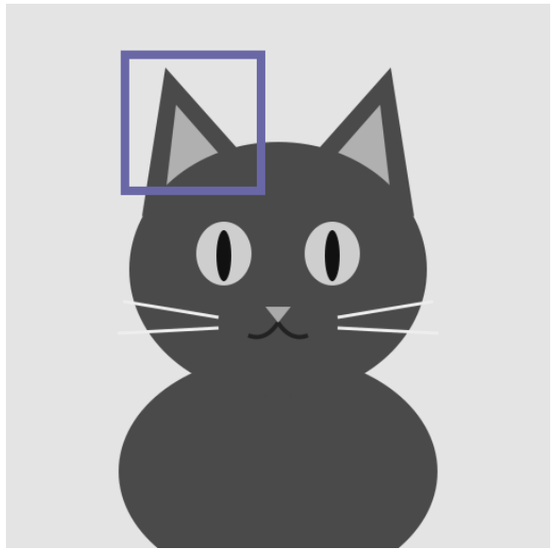
오늘의 질문: **열 이름이 없는 '사진'이나 '글'을 받은 AI**는, 무엇을 보고 판단할까?

지난주 숲(랜덤 포레스트)의 변수 중요도도 '맞히는 데 많이 쓴 변수'였을 뿐 '원인'은 아니었다. 오늘의 AI도 '맞히는 데 쓸모 있었던 단서'를 찾는다 — 그 단서가 엉뚱하다면?

AI의 눈에는 사진이 '숫자표'로 보인다

고양이 사진의 귀 부분을 크게 확대해 보면?

① 사람의 눈



"뾰족한 귀가 있는 고양이!"
(보라 상자 = 확대할 귀 부분)

② 확대한 귀



작은 조각 하나가
'밝기 숫자' 칸 64개

③ 컴퓨터의 눈

158	182	177	181	182	182	182	153
189	226	161	204	228	228	228	181
189	220	112	119	210	228	228	181
189	210	108	114	130	216	228	181
189	197	107	164	117	140	217	176
189	179	108	173	154	93	111	110
189	158	111	135	92	76	74	89
158	130	100	94	89	89	89	98

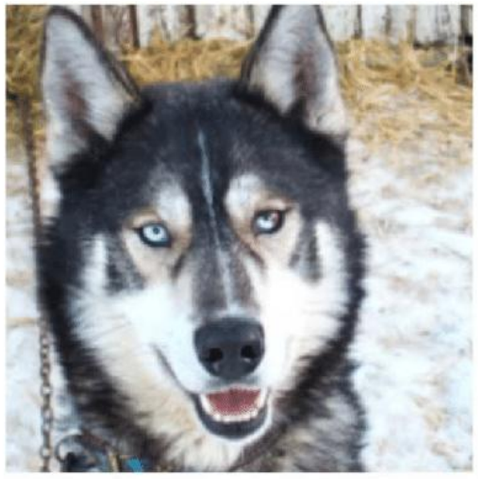
0(검정)~255(흰색)
숫자 64개가 전부

AI는 '귀'도 '고양이'도 모른다. 숫자 속에서 **쓸모 있는 단서**를 스스로 찾아야 한다 →
그 단서가 바로 **특징(feature)**

지난주: 표의 열은 사람이 이름을 붙여 줬다 → 오늘: 사진에는 열 이름이 없다. "무엇을 열로 삼을까?"부터 AI가 정한다

오늘의 핵심 질문 하나

AI가 정답을 맞혔다면,
올바른 이유로 맞힌 것일까?





이유가 맞는 맞힘

- 늑대의 **얼굴·귀·털 모양**을 보고 "늑대"라고 답했다
- 새로운 장소에서 찍어도 맞힌다

우연한 단서로 맞힘

- 늑대 사진에 늘 찍혀 있던 **눈(雪) 배경**을 보고 "늑대"라고 답했다
- 눈 위의 강아지도 늑대가 된다

각자 하나 골라 두자: ① 정답률 높으면 이유도 맞다 ② 정답률만으로는 알 수 없다

AI에게 ‘특징’이란 무엇일까

1교시 · 판단에 쓰는 단서를 찾아서

먼저 해 보자: 고양이와 강아지, 무엇으로 구분할까? (2분)

사진 한 장만 보고 둘을 가를 수 있는 '단서'를 3개 이상 말해 보자

눈동자

세로로 가늘어지나, 둥근가

귀

뾰족하게 서 있나, 늘어졌나

주둥이

짧고 납작한가, 길게 나왔나

수염

길고 뚜렷한가

몸집

작은가, 다양한가

자세

앉은 모양, 꼬리 위치

생각할 거리

- '몸집'은 왜 약한 단서일까? (작은 강아지, 큰 고양이)
- '야옹 소리', '성격'은 좋은 단서지만 사진 한 장에는 담기지 않는다

방금 한 일이 **AI가 하는 일의 출발점**: 데이터를 보고 "무엇을 보면 둘이 갈리는가"를 찾는 것. 이 단서를 AI에서는 **특징(feature)** 이라고 부른다

스무고개 질문 = 단서. "귀가 뾰족한가?"는 지난주 트리의 질문과 똑같은 모양이다.

특징(feature) = 판단에 쓰는 단서

데이터에서 뽑아낸, 정답을 가르는 데 쓰는 단서.

장면	데이터	특징(단서)	정답
과일 맞히기 (지난주)	과일 16종	색 · 크기 · 껍질 · 씨	어떤 과일인가
놀이공원 (지난주)	주말 기록 12회	날씨 · 주말 · 기온	간다 / 안 간다
오늘: 사진	고양이·강아지 사진 수천 장	모양 · 질감 · 색 분포 · 위치	고양이 / 강아지
오늘: 글	메일 수천 통	'무료' 횟수 · 느낌표 수 · 링크 수	스팸 / 정상

트리와 오늘의 AI, 무엇이 같고 다를까?

- 같다: 단서를 보고 갈라 판단한다
- 다르다: 트리는 **사람이 준 열 중에서 고르고**, 사진 AI는 **무엇을 볼지부터 스스로 찾는다**

AI의 실력은 '얼마나 **좋은 단서**를 찾았느냐'로 정해진다

그렇다면 '좋은 단서'란 무엇일까? 먼저 퀴즈로 감을 잡아 보자

사진만이 아니다: 글과 숫자에도 특징이 있다

데이터 종류는 달라도 구조는 같다: 원재료 → 단서(특징) 뽑기 → 판단

이미지

사진 속 동물 분류

원재료: 점(픽셀)의 밝기·색 숫자

단서: 선, 모양, 색의 분포, 질감

→ **판단:** 고양이 / 강아지

이렇게도 쓰인다: 불량품 검사 · 의료 영상 · 자율주행

텍스트

스팸 메일 걸러내기

원재료: 글자와 단어

단서: '무료' 횟수, 느낌표 수, 링크 수

→ **판단:** 스팸 / 정상

이렇게도 쓰인다: 리뷰 감정 분석 · 악성 댓글 탐지

수치

구독 해지 예측

원재료: 나이, 접속 기록, 결제액

단서: 마지막 접속 후 며칠 지났는지, 한 달 사용 시간

→ **판단:** 해지 위험 / 유지

이렇게도 쓰인다: 대출 심사 · 수요 예측

세 곳 모두 같은 질문: "이 단서는 **쓸 만한가?**"

퀴즈 ① 좋은 단서 vs 나쁜 단서

사과와 귤을 구별하는 AI를 만든다. 다음 중 가장 나쁜 단서는?

A 껍질의 색

B 표면의 질감 (매끈 vs 오돌토돌)

C 가게에서 붙인 가격표 스티커

D 전체 모양과 크기

퀴즈 ① 해설: 정답 C — 가격표

C. 가격표 스티커는 과일 자체의 성질이 아니라 우연히 함께 있던 정보다

다른 가게에서는 바로 틀린다

- 우리 동네 가게: 사과에만 '1,500원' 스티커
- 다른 가게: 귤에도 '1,500원' 스티커
- → AI는 스티커만 보고 '사과'라고 우긴다

A·B·D는 과일 자체에서 나온다

- 색·질감·모양은 사과와 귤이 **정말로 다른 곳**
- 장소가 바뀌어도 **그대로 유지**된다
- → 상황이 바뀌어도 통하는 단서

좋은 단서는 **대상 자체**에서 나오고, **상황이 바뀌어도 유지**되는 것!

글의 특징 들여다보기: 스팸 메일은 무엇으로 들킬까

두 메일 중 어느 쪽이 스팸일까? 무엇을 보고 알았는지 '단서'를 말해 보자

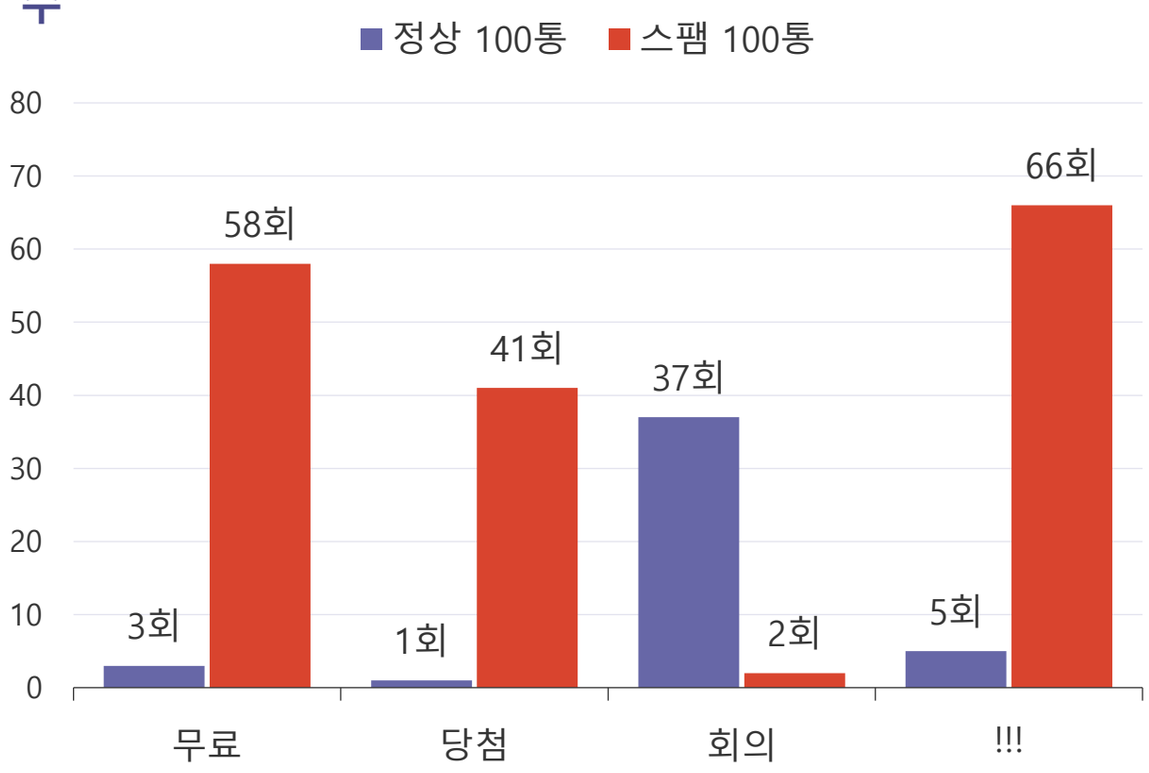
메일 A 발신: event@lucky-win.biz

축하합니다!!! **무료** 경품 **당첨**!!!
지금 바로 클릭하세요 → 링크1 링크2 링크3

메일 B 발신: 학과사무실

다음 주 화요일 특강 장소가 **공학관 301호**로 변경되었습니다. 참고 바랍니다.

정상 메일 100통 vs 스팸 메일 100통에서 단어가 나온 횟수



생각해 보기: 평소 쓰는 쇼핑몰에서 "**무료 배송 안내!**" 메일이 왔다면?
→ '무료' 하나만 보면 스팸, **발신자까지 보면 정상**. 단서는 여럿을 함께 봐야 한다

글도 AI에게는 '단어가 몇 번 나왔나' 같은 **숫자 단서**로 바뀐다. 사진의 픽셀과 같은 처지다 (표의 숫자는 수업용 예시)

좋은 특징의 세 조건

퀴즈의 '가격표'는 왜 나쁜 단서였을까? 세 가지 눈금으로 점검한다

1 구분력



종류마다 다르게 나타난다

나쁜 예
고양이·강아지 둘 다 '털이 있다'
→ 못 가른다

2 안정성



조건이 바뀌어도 유지된다

나쁜 예
'사진 밝기'는 조명만 바꿔도 달라진다

3 관련성



정답과 진짜로 관련 있다

나쁜 예
'배경이 거실'은 우연히 함께 찍혔을 뿐

가격표 스티커는 ③ **관련성**이 없는 단서였다. 오늘 수업은 ③ 관련성이 **무너질 때**를 집중해서 본다

함께 해보기① 단서 찾기 게임 (개인 활동지 A면)

개인 + 짝 활동 | 12분 | 두 대상을 가르는 '좋은 단서'를 찾고, 점수를 매긴다

1 짝 고르기 (1분)

아래 중 하나를 고른다: 사과 vs 토마토 / 진짜 리뷰 vs 광고 리뷰 / 고양이 vs 강아지

2 단서 5개 적기 (4분)

사진이나 글만 보고 확인할 수 있는 단서만 적는다 (혼자 적고 → 짝과 비교)

3 별점 매기기 (3분)

단서마다 구분력·안정성·관련성을 ★1~3으로 매긴다

4 발표 (4분)

별이 가장 많은 단서 1개 + '함정 단서' 1개를 말한다

함정 단서란?

정답과 **우연히 함께** 나타나지만 진짜 이유는 아닌 단서

예: "광고 리뷰는 대개 별 5개" → 진짜 리뷰도 별 5개가 많다

준비물 · 결과물

- 활동지 A면 + 필기구 (기기 필요 없음)
- A면 표 완성 + 대표 단서 1개 발표

정답: 없음! 단서를 '왜 좋다/나쁘다'고 판단했는지 **이유**를 말할 수 있으면 성공

예시 해설: 사과 vs 토마토

같은 '빨간 둥근 물체'라도, 어떤 단서를 쓰느냐에 따라 판단의 질이 갈린다

좋은 단서 (구분력·안정성·관련성 ✓)

- **꼭지 모양**: 사과는 가는 줄기, 토마토는 별 모양 초록 꽃받침
- **표면**: 사과는 단단하고 매끈, 토마토는 얇고 윤기
- **자른 단면**: 사과는 씨방 5칸, 토마토는 젤리 속 작은 씨

조명·각도가 바뀌어도 대부분 유지된다

함정 단서 (우연히 함께 나타날 뿐)

- **빨간색**: 둘 다 빨갛다 → 구분력 없음
- **사진 밝기**: 조명에 따라 달라진다 → 안정성 없음
- **배경**(과일 바구니 vs 샐러드 접시): 찍은 장소일 뿐 → 관련성 없음

학습 사진에 우연히 많으면 AI가 붙잡는다

2교시 질문: 사람은 '배경은 상관없다'를 상식으로 안다. **상식이 없는 AI**가 배경만 보고도 계속 맞힌다면, 배경을 버릴 이유가 있을까?

1교시 정리

1

특징은 판단에 쓰는 단서다

과일의 색·크기, 놀이공원의 날씨, 사진의 모양, 메일의 '무료' 횟수. 데이터가 달라도 '원재료 → 단서 → 판단' 구조는 같다

2

좋은 특징은 구분력·안정성·관련성을 갖춘다

종류마다 다르게 나타나고, 조건이 바뀌어도 유지되고, 정답과 진짜로 관련 있어야 한다

3

이미지 AI는 무엇을 볼지 스스로 정한다

그래서 AI가 어떤 단서를 썼는지 사람이 바로 알기 어렵다 → 2교시의 질문

쉬는 시간 10분 · 돌아오면 '맞혔지만 엉뚱한 것을 본 AI'의 정체를 파헤친다

AI는 무엇을 보고 판단했을까

2교시 · 맞혔지만 엉뚱한 것을 본 AI

100여 년 전의 경고: 영리한 말 '한스'

1900년대 초 독일 베를린. "3 더하기 2는?" 하고 물으면 **발굽을 다섯 번 구르는 말**이 있었다

겉으로 보인 것

덧셈·날짜 계산을 척척 맞힌다. 정답률이 매우 높았다

실험으로 바꿔 본 것

질문자가 답을 모르게 하거나, 한스가 질문자를 못 보게 했다

드러난 사실

정답률이 뚝 떨어졌다. 한스는 질문자의 표정·자세 변화를 보고 멈췄다

한스가 실제로 본 단서

- 질문자가 정답 횟수에 가까워질 때 무의식적으로 풀리는 **긴장**
- 정답과 늘 함께 나타났으니 아주 쓸모 있는 단서였다

조사를 이끈 방법

- **한 번에 조건 하나만** 바꿔 보기
- → 3교시에 우리가 AI에게 똑같이 해 본다

교훈: 정답률이 높다는 것만으로는 **무엇을 보고 맞혔는지** 알 수 없다. 조건을 바꿔 봐야 드러난다

AI판 한스: 늑대와 허스키를 가른 것은 '눈(雪)'이었다

3주차·5주차에 본 '눈밭의 허스키', 기억나나요? 오늘은 왜 그런 일이 생기는지, 어떻게 확인하는지까지 들여다본다



학습 사진: 늑대 = 눈 덮인 숲



시험: 배경이 눈이면 허스키도 '늑대'

정답률은 꽤 높았다

그런데 무엇을 보고 맞혔을까?

① 학습한 사진

늑대 사진: 대부분 눈 덮인 숲
허스키 사진: 대부분 풀밭·집 앞
→ '눈'이 정답과 늘 함께 나왔다

② 시험한 사진

눈 위에서 찍은 허스키 → AI: "늑대"
풀밭의 늑대 → AI: "허스키"

③ 들여다보니

AI가 주목한 영역은 동물이 아니라 **배경의 하얀 눈**
AI는 '늑대 탐지기'가 아니라 '눈 탐지기'였다

AI의 목표는 '학습 사진의 정답 맞히기'뿐. 눈은 털 모양보다 **찾기 쉬운데 정답과 늘 함께** 나왔다.
상식이 없는 AI에게는 가장 효율적인 단서!

출처: Ribeiro, Singh & Guestrin (2016), "Why Should I Trust You?" — 판단 이유를 확인하는 도구의 필요성을 보이려고 설계한 실험 (그림은 설명용 일러스트)

지름길 단서: 정답 대신 '정답 옆에 있던 것'을 외운다

정답과 '우연히 함께 나타난' 단서를 진짜 이유처럼 쓰는 것. 새로운 장소에서 무너진다

지난주의 징크스

빨간 양말을 신은 날 세 번 시험을 잘 봤다

→ "빨간 양말 = 고득점"

적은 경험에서 우연을 규칙으로 믿었다 (과대적합). AI도 같은 실수를 한다

풀밭의 소, 해변의 소

소 사진은 대부분 초원에서 찍힌다

→ 해변에 선 소를 잘 못 알아본다

배경 = 지름길 단서 (연구 보고: Beery 외, 2018)

병원마다 다른 X-ray

폐렴 판별 AI가 영상 속 병원 표식·장비 특징을 단서로 쓸 수 있다

→ 병원이 바뀌면 성능이 떨어졌다

촬영 장소 = 지름길 단서 (연구 보고: Zech 외, 2018)

공통점: AI는 '진짜 이유'가 아니라 학습 때 **정답과 늘 같이 있던 것**을 붙잡는다 → 관련성(③)이 무너진 단서

퀴즈 ② 이 AI는 무엇을 봤을까?

피부 사진으로 악성 여부를 가르는 AI. 학습 사진 중 악성 사진에는 크기를 재려고 '자(눈금자)'를 함께 찍은 경우가 많았다. AI가 쉽게 기댈 수 있는 단서는?

A 병변의 색과 모양

B 사진 속 자(눈금자)

C 환자의 나이

D 사진의 해상도

'정답과 늘 함께 나온 것'이 무엇인지 찾아보세요. 30초!

퀴즈 ② 해설: 정답 B — 사진 속 자(눈금자)

AI가 자를 '악성의 신호'로 배웠을 수 있다. 병과는 아무 관련 없는 우연한 단서!

무슨 일이 생길까?

- 학습 때: 자가 있는 사진 → 악성 → 정답률 높음
- 새 병원에서 자 없이 찍으면 → 맞힐 단서가 사라진다
- 자를 붙여 찍은 **양성** 사진 → 악성으로 오판

한스·눈 배경과 같은 구조

	정답 옆에 있던 것
한스	질문자의 표정
늑대 AI	배경의 눈
피부 AI	사진 속 자

정답률이 높아도 안심하면 안 된다. **AI가 어디를 봤는지** 확인해야 한다 (→ 곧 배운다)

학습데이터가 AI의 눈을 만든다

AI는 보여 준 사진만큼만 세상을 안다. 데이터의 쏠림은 그대로 판단의 쏠림이 된다

1

무엇이 많은가

한쪽 사례가 압도적으로 많으면 적은 쪽을 잘 못 배운다

예: 밝은 낮 사진만 잔뜩 → 밤에 약하다

2

무엇이 함께 나오는가

정답과 늘 같이 찍힌 것을 단서로 삼는다

예: 늑대 + 눈, 소 + 초원, 악성 + 자

3

무엇이 빠져 있는가

한 번도 못 본 경우는 짐작조차 못 한다

예: 휠체어 탄 보행자 사진이 없다면?



특정 상황의 사진만 모아 학습하면
처음 보는 조건은 틀리기 쉽다

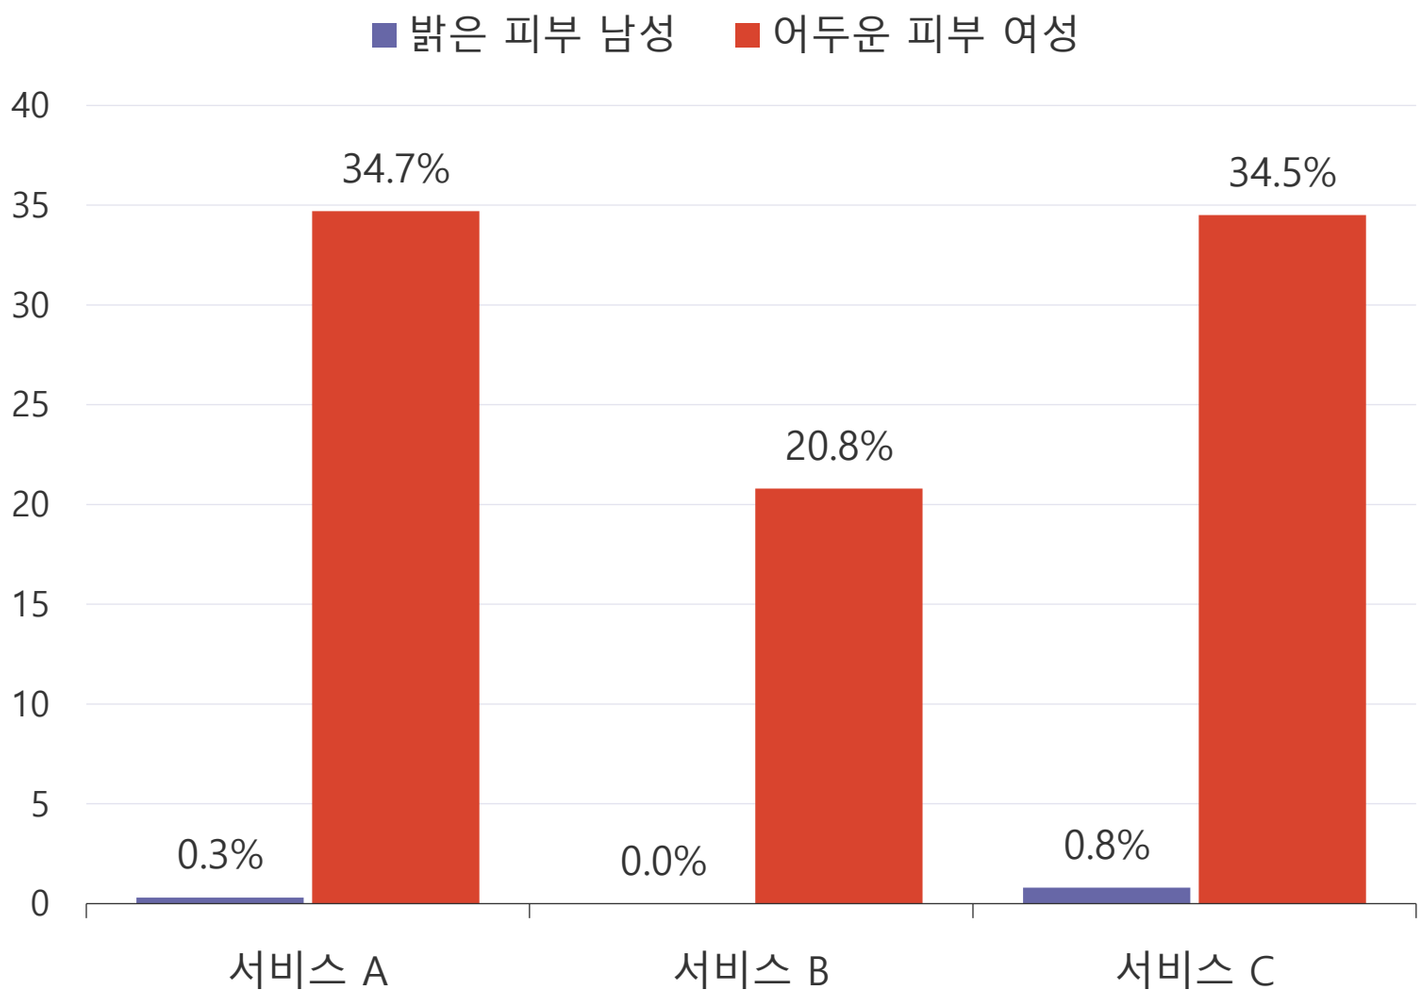
한 줄 정리

AI가 **나빠서**가 아니라 데이터가 **세상을 고르게 담지 못해서** 생기는 문제가 많다

그래서 AI를 평가할 때는 “정답률이 몇 %?”와 함께 “**어떤 데이터로 배웠나?**”를 묻는다

사례: 얼굴 분석 AI의 성별 판별 오류율

상용 얼굴 분석 서비스 3종을 시험한 보고 (Buolamwini & Gebru, 2018) — 집단별 오류율



왜 이런 차이가 생겼을까?

- 학습·평가에 쓰인 얼굴 사진이 **특정 집단에 쏠려** 있었다는 분석이 나왔다
- 전체 정확도만 보면 '잘 되는 AI'로 보인다
- **집단별로 나눠 봐야** 숨은 격차가 보인다

AI가 나빠서가 아니라, **데이터가 세상을 고르게 담지 못해서**. 평균 점수 뒤에 숨은 집단별 점수를 확인하자

함께 해보기 · 어떤 열을 특징으로 써도 될까? (개인 활동지 B면)

대출을 **값을 사람인지 예측**하는 AI를 만든다. 아래 열 중 특징으로 써도 되는 것은? 혼자 ○ / △ / × 로 표시해 보자 (3분)

월 소득

○ △ ×

과거 연체 기록

○ △ ×

현재 직장 근속 연수

○ △ ×

사는 동네(우편번호)

○ △ ×

나이

○ △ ×

휴대폰 기종

○ △ ×

성별

○ △ ×

이름

○ △ ×

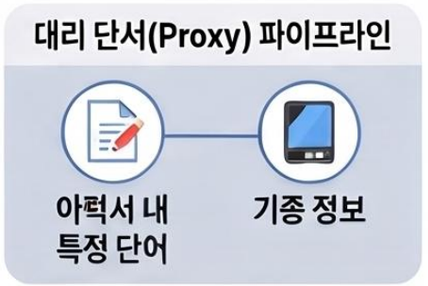
판단할 때 던질 질문 세 가지

- 이 열은 '값을 능력'과 **진짜로 관련** 있는가? (관련성)
- 이 열을 쓰면 **특정 집단이 불리**해지지 않는가? (공정성)
- 이 열을 빼도, **다른 열이 같은 정보를 몰래** 담고 있지는 않은가? (대리 단서)

해설: 지워도 남는 '대리 단서'를 조심하자

열	판정	이유
월 소득	○	상환 능력과 직접 관련
과거 연체 기록	○	과거 행동 기록, 관련성 높음
근속 연수	△	관련은 있으나 직업 형태에 따라 불리
사는 동네	×	소득·인종 등의 '대리 단서'가 될 수 있음
나이	△	법·정책상 제한 가능
휴대폰 기종	△	소득의 대리 단서일 수 있음
성별·이름	×	갚을 능력과 무관 + 차별 위험





실제 사례: 이력서 AI (2018 보도)

- 과거 10년 이력서로 지원자 평가 AI를 만들었는데 지원자 대부분이 남성이었다
- '여자 체스 동아리'처럼 women's가 들어간 이력서를 낮게 평가하는 경향
- 단어를 지워도 우회 단서가 남을 수 있어 사용을 중단했다고 보도 (Reuters)

특징 선택은 기술 문제이면서 **공정성의 문제**. 열을 지우는 것만으로는 부족하고 **결과가 집단별로 어떻게 다른지** 확인해야 한다

※ 판정은 수업용 토론 예시입니다. 정답이 하나로 정해진 문제가 아니에요 — 이유를 말할 수 있으면 됩니다.

AI가 어디를 봤는지 확인하는 세 가지 방법

AI의 머릿속 숫자를 직접 읽을 수는 없다. 대신 '**무엇을 바꾸면 답이 바뀌는가**'로 거꾸로 알아낸다

1 주목 영역 지도 (히트맵)



사진 위에 AI가 많이 본 곳을 색으로 칠한다

예: 늑대 사진에서 칠해진 곳이 동물이 아니라 눈이었다

2 가려 보기

사진의 일부를 가리고 답이 바뀌는지 본다

예: 귀를 가렸더니 답이 바뀐다 → 귀가 중요한 단서

3 변수 중요도 (지난주)

표 데이터에서 판단에 많이 쓰인 열을 숫자로 보여 준다

예: 놀이공원 숲 — 날씨 0.58, 주말 0.34, 기온 0.08

3교시 예고: 우리는 AI 내부를 볼 수 없는 '사용자'다. 그래도 **한스를 조사한 방법**처럼 조건을 하나씩 바꾸고 답이 바뀌는 순간을 기록하면 AI가 기댄 단서를 추론할 수 있다

2교시 정리

1

정답률이 높아도 '무엇을 보고' 맞혔는지는 모른다

한스는 질문자의 표정을, 늑대 분류 AI는 배경의 눈을 봤다. 조건을 바꿔 봐야 드러난다

2

AI는 정답 옆에 있던 것을 지름길 단서로 삼는다

학습데이터에서 정답과 늘 함께 나온 배경·장소·표식. 학습 때는 통하지만 새로운 조건에서 무너진다

3

학습데이터와 특징 선택이 AI의 눈을 만든다

많은 것·함께 나오는 것·빠진 것이 판단의 쏠림이 된다. 열을 지워도 대리 단서가 남을 수 있다

다음은 직접 AI를 흔들어 보는 시간! 같은 물건, 다른 조건

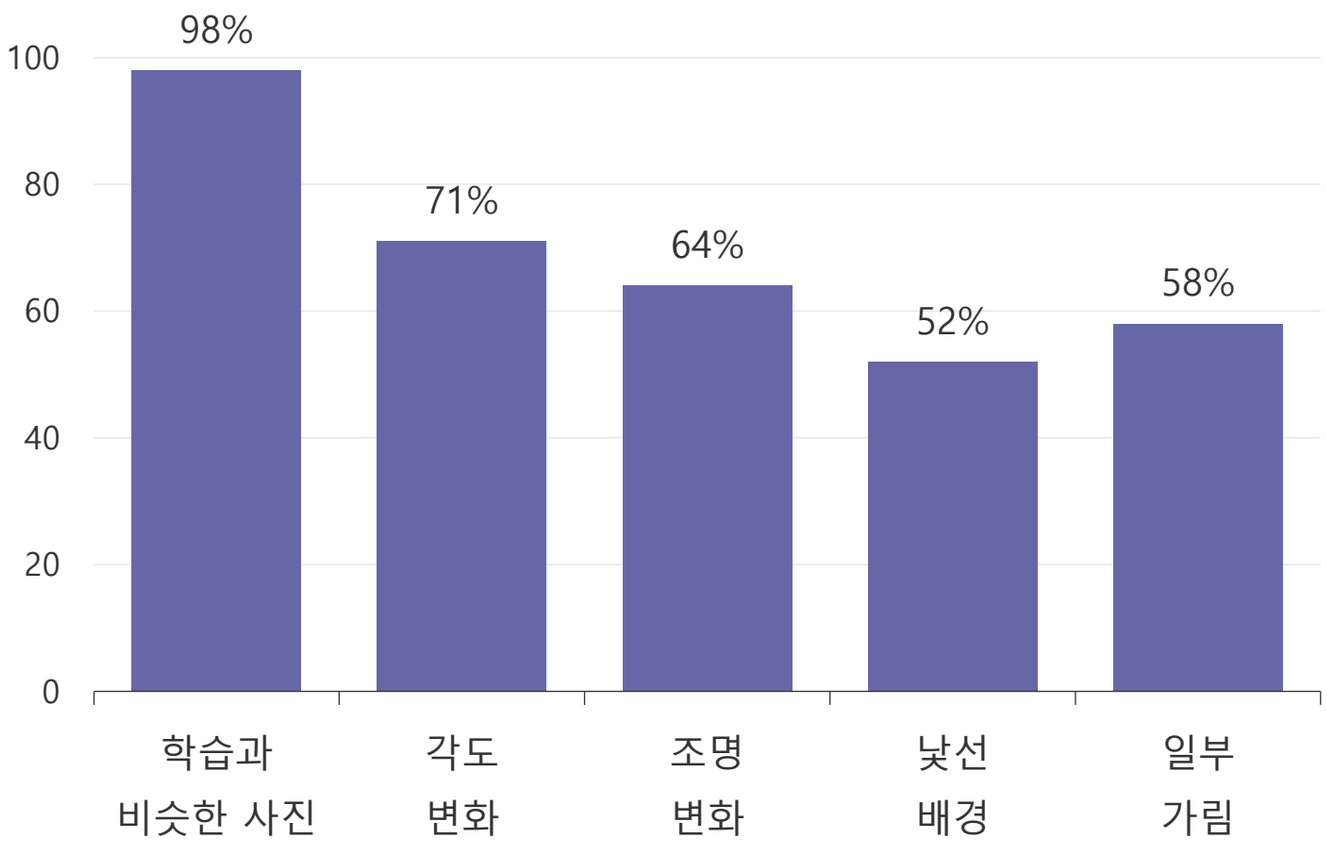
조건이 바뀌면 AI는 왜 틀릴까

3교시 · 같은 물건, 다른 조건 실험

연습과 실전이 다르면 AI는 흔들린다

AI가 배운 사진(연습)과 실제로 들어오는 사진(실전)이 다르면, 연습에서 쓸모 있던 단서가 사라지거나 엉뚱한 단서가 나타난다

같은 AI의 정확도 (수업용 예시 숫자)



지난주 표현으로 바꾸면

- 연습 문제(훈련 데이터)만 잘 푸는 학생은 처음 보는 시험(테스트 데이터)에서 무너진다
- 오늘의 AI도 마찬가지: 학습 사진에서 100점이어도 실전 조건이 다르면 점수가 떨어진다
- 그래서 좋은 AI는 **다양한 조건**으로 배우고, **다양한 조건**으로 시험 본다

조건마다 AI가 기대던 **단서가 사라지거나 새로 생긴다.** 오늘 실험의 목표는 그 단서를 추론하는 것

AI를 흔드는 네 가지 조건

조건마다 사라지는 단서와 새로 생기는 단서가 다르다

각도

바꾸는 법: 위·옆·아래·뒤집기

평소 보이던 모양(윤곽)이 사라진다

예상 오류: 머그컵을 위에서 찍으면 "그릇"?

조명

바꾸는 법: 어둡게·역광·색 조명

색과 질감 단서가 흐려지거나 바뀐다

예상 오류: 노란 조명 아래 흰 신발 → "베이지 가방"?

배경

바꾸는 법: 낯선 장소·복잡한 배경

배경이 새로운(엉뚱한) 단서가 된다

예상 오류: 욕실 바닥의 운동화 → "슬리퍼"?

가림

바꾸는 법: 손·다른 물건으로 일부 가림

핵심 부분 단서가 사라진다

예상 오류: 손잡이를 가린 가위 → "집게"?

사람에게는 쉬운 변화도, **학습데이터에 없던 조건**이면 AI에게는 낯선 문제다

사람 눈에는 똑같은데 AI는 다르게 본다

조건을 크게 바꾸지 않아도, 사람은 못 알아챌 만큼 작은 변화로 AI의 답이 뒤집히기도 한다

판다 + 눈에 안 보이는 잡음

판다 57.7%

+ 변화

긴팔원숭이 99.3%

사람 눈에는 두 사진이 똑같은 판다. AI는 오히려 더 확신하며 틀렸다

Goodfellow 외 (2015)

정지 표지판 + 스티커 몇 장

정지 표지판

+ 변화

속도 제한 표지판

낙서처럼 보이는 흑백 스티커로 인식 AI가 표지판을 잘못 읽는 경우가 많았다. 자율주행에서 '튼튼한 인식'이 중요한 이유

Eykholt 외 (2018)

바나나 옆 알록달록한 패치

바나나

+ 변화

토스터

패치를 놓자 인식 AI가 바나나 대신 '토스터'로 판단. 무늬가 진짜 대상보다 더 강한 단서가 되었다

Brown 외 (2017)

AI의 **확신도가 높다고 맞는 것은 아니다.** AI가 쓰는 단서는 사람과 다를 수 있다 → 그래서 직접 바꿔 보고 확인해야 한다

실험 설계 팁: 한 번에 하나만 바꾼다

한스를 조사한 방법과 같은 원칙: 나머지는 그대로 두고 **조건 하나만** 바꾼다

나쁜 실험

기준: 책상 위, 밝은 곳, 정면
2번 사진: **바닥에서, 어두운 곳, 위에서** 찍었다
AI 답이 바뀌었다
→ 바닥 때문? 어두워서? 각도 때문?
원인을 알 수 없다

좋은 실험

기준: 책상 위, 밝은 곳, 정면
2번: 책상 위, 밝은 곳, **위에서** (각도만 바꿈)
3번: 책상 위, **어두운 곳**, 정면 (조명만 바꿈)
답이 바뀌면 **그 조건이 원인 후보**

기록할 것 세 가지

① 무엇을 바꿨나 (조건 하나)　② AI의 1순위 답과 확신도　③ 기준 사진과 비교해 맞았나 / 틀렸나

함께 해보기② 같은 물건, 다른 조건 실험

팀 실험 + 개인 기록 **25분** 조건을 하나씩 바꾸며 AI의 답이 바뀌는 순간을 기록한다

1 **물건 정하기 · 기준 사진 (3분)**
팀 물건 1개. 밝은 곳·깨끗한 배경·정면에서 찍은 기준 사진을 AI에 넣고 결과 기록

2 **각도 바꾸기 (4분)**
위·옆·뒤집기 중 2가지. 나머지 조건은 기준 사진과 똑같이

3 **조명 바꾸기 (4분)**
휴대폰 손전등 역광, 어두운 곳, 색 있는 화면 빛 등

4 **배경 바꾸기 (4분)**
책상 위 → 가방 속, 바닥, 복잡한 물건 더미 위 등

5 **가림 (4분)**
손·종이로 25%, 50% 가리기. 어느 부분을 가렸는지 기록

6 **원인 추론 (6분)**
답이 바뀐 조건마다 '사라진 단서 / 새로 생긴 단서'를 쓴다

사용할 AI 도구 (택1)

- Google 렌즈 (Google 앱·카메라)
- 네이버 앱 스마트렌즈
- 기타 사진 검색·인식 기능
- 결과가 '이름 + 비슷한 이미지'면 **1순위 이름**을 기록

실험 규칙

- 한 번에 조건 **하나만** 바꾼다
- 사진마다 번호를 붙여 저장
- 얼굴 대신 **물건**만 찍는다
- 기기 없는 팀: 옆 팀과 짝 / 교수자 화면

기록 예시: 텀블러로 해 본 실험

기록 형식을 보여 주는 예시다. 우리 팀의 결과는 다를 수 있고, **다른 것이 정상**이다

조건	바꾼 내용	AI 1순위 (확신도)	맞음?	추론: 사라진 / 새로 생긴 단서
기준	책상 위 · 밝게 · 정면	텀블러 (92%)	○	몸통 모양과 뚜껑이 보임
각도	위에서 내려다봄	컵 (61%)	△	뚜껑 윤곽이 사라지고 동그란 모양만 남음
조명	어두운 곳	병 (48%)	×	표면 반사·색 단서가 흐려짐
배경	가방 속	텀블러 (78%)	○	배경이 바뀌어도 몸통 모양 유지
가림	손으로 50% 가림	머그컵 (44%)	△	뚜껑이 가려져 핵심 단서가 사라짐

원인을 쓰는 문장 틀

"AI는 ___ 조건에서 ___을(를) ___(으)로 판단했다. 이 조건에서 ___ 단서가 사라졌거나 ___ 단서가 새로 생겼기 때문으로 추론한다. 근거는 ___ 이다."

더 튼튼한 AI를 만드는 방법

문제가 데이터에서 왔으니 해결도 대부분 데이터에서 시작한다

1 다양한 조건으로 배우기

밤·역광·여러 각도·여러 배경 사진을 일부러 모은다. 사진을 돌리고 밝기를 바꿔 늘리기도 한다

2 지름길 단서 끊기

늑대를 풀밭에서도, 허스키를 눈 위에서도 찍은 사진을 넣는다. 정답과 배경이 늘 같이 나오지 않게

3 다양한 조건으로 시험 보기

테스트 사진도 실전처럼 다양하게. 조건별·집단별 점수를 따로 확인한다

4 판단 이유 확인 + 사람의 검토

히트맵·가려 보기로 단서를 점검하고, 중요한 결정은 사람이 최종 확인한다

지난주와 같은 생각: 랜덤 포레스트는 트리마다 다른 데이터를 보여 **'다르게 틀리게'** 만들었다. 튼튼한 AI도 다양한 조건을 보여 한 가지 단서에 기대지 않게 만든다

체크 퀴즈: 세 문제, 손으로 답하기

Q1

늑대·허스키 분류 AI가 실제로 주로 쓴 단서는?

① 귀 모양

② 배경의 눈

③ 털 색

내 답: _____

Q2

실험에서 조건을 한 번에 하나만 바꾸는 이유는?

① 시간이 덜 들어서

② 어떤 조건이 답을 바꿨는지 알 수 있어서

③ AI가 더 정확해져서

내 답: _____

Q3

좋은 특징의 조건이 아닌 것은?

① 종류마다 다르게 나타난다

② 조건이 바뀌어도 유지된다

③ 학습 사진에 늘 함께 찍혀 있다

내 답: _____

체크 퀴즈: 정답과 해설

Q1

늑대·허스키 분류 AI가 실제로 주로 쓴 단서는?

① 귀 모양

② 배경의 눈

③ 털 색

정답: ② — 학습 사진에서 늑대 = 눈 배경이 늘 함께 나와, 배경이 지름길 단서가 되었다

Q2

실험에서 조건을 한 번에 하나만 바꾸는 이유는?

① 시간이 덜 들어서

② 어떤 조건이 답을 바꿨는지 알 수 있어서

③ AI가 더 정확해져서

정답: ② — 두 조건을 동시에 바꾸면 원인을 가를 수 없다. 한스 조사와 같은 원칙

Q3

좋은 특징의 조건이 아닌 것은?

① 종류마다 다르게 나타난다

② 조건이 바뀌어도 유지된다

③ 학습 사진에 늘 함께 찍혀 있다

정답: ③ — 늘 함께 찍힌 것은 지름길 단서일 수 있다. 관련성을 따로 확인해야 한다

오늘 우리가 익힌 것

1

특징은 판단에 쓰는 단서다

이미지·텍스트·수치 모두 '원재료 → 단서 → 판단'. 좋은 단서는 구분력·안정성·관련성을 갖춘다

2

이미지 AI는 무엇을 볼지 스스로 정한다

그래서 정답률만으로는 올바른 단서를 썼는지 알 수 없다

3

AI는 정답 옆에 있던 것을 지름길 단서로 삼는다

늑대와 눈, 소와 초원, 병원 표식, 사진 속 자. 학습데이터의 쏠림이 판단의 쏠림이 된다

4

연습과 실전이 다르면 AI는 흔들린다

각도·조명·배경·가림이 바뀌면 단서가 사라지거나 엉뚱한 단서가 생긴다

5

조건을 하나씩 바꿔 보면 AI가 기댄 단서를 추론할 수 있다

사용자도 할 수 있는 검증. 더 튼튼한 AI는 다양한 조건의 데이터에서 나온다